

LOREON — Specifica formale del modello generativo unificato per la quantificazione di comunità da amplicon long-read

Modello, algoritmo EM, modello d'errore indel-aware e protocollo di benchmark

Documento tecnico di design — progetto LOREON / TaxQuality

July 24, 2026

Abstract

Questa specifica formalizza il modulo TaxQuality come un *unico* modello generativo probabilistico dei dati di sequenziamento long-read (Oxford Nanopore) per marcatori metabarcoding (ITS, 16S, LSU, SSU). Da una sola verosimiglianza derivano, in modo coerente: (i) l'abbondanza delle unità tassonomiche, (ii) la risoluzione tassonomica per-lettura e per-OTU, (iii) il tasso di chimere/rumore, e (iv) — elemento distintivo — l'incertezza *calibrata* su abbondanze e diversità. Il modello incorpora un modello d'errore *indel-aware* (l'errore ONT è dominato da inserzioni/delezioni) e una componente di mistura per le letture chimeriche. L'inferenza è per massima verosimiglianza tramite Expectation–Maximization (EM), di cui si fornisce la derivazione completa. Ci si posiziona rispetto al prior art più vicino (Emu, *Nature Methods* 2022, EM per abbondanza 16S long-read): il contributo è il trattamento *congiunto* di errore indel-aware, chimere e risoluzione, con quantificazione dell'incertezza calibrata e validazione cross-marcatore. Chiude un protocollo di benchmark dettagliato.

1 Introduzione e relazione con lo stato dell'arte

La quantificazione da amplicon long-read soffre di tre problemi che oggi si affrontano con euristiche separate: l'*ambiguità di mappaggio* (letture che corrispondono a più riferimenti quasi identici, es. le *Species Hypothesis* di UNITE), il *rumore/chimere* (letture spezzate da artefatti di PCR o giunzioni), e l'*errore di sequenziamento* ONT (elevato e indel-dominante). La ridistribuzione delle letture multi-mapping per massima verosimiglianza tramite EM è consolidata nella quantificazione RNA-seq (RSEM [4], kallisto [5], Salmon [6]) e in metagenomica (Bracken [7]); **Emu** [8] la porta agli amplicon 16S full-length ONT con un EM su un profilo d'errore.

Rispetto a Emu, che stima le sole abbondanze (16S, stime puntuali), questa specifica: (a) usa un modello d'errore *indel-aware* esplicito; (b) integra una *componente chimera* nella stessa verosimiglianza; (c) restituisce la *risoluzione tassonomica* come probabilità posteriore; (d) fornisce *intervalli di credibilità calibrati* su abbondanze e indici di diversità; (e) è *multi-marcatore* (incluso l'ITS, dove l'over-split delle SH è critico [11, 12]). Il modello d'errore condizionato all'allineamento segue la logica dei pair-HMM [2]; l'EM è quello classico [1].

2 Notazione e dati osservati

Consideriamo un campione con letture $r = 1, \dots, N$. minimap2 [3] (con allineamenti secondari attivi, -N/-p, e supplementari) fornisce per ogni lettura un insieme di allineamenti candidati verso i riferimenti j di un database (es. UNITE); sia $\mathcal{C}_r \subseteq \{1, \dots, J\}$ l'insieme dei riferimenti candidati per la lettura r (primario + secondari che superano un filtro minimo di qualità). Dall'allineamento $r \rightarrow j$ (CIGAR + tag NM/cs) estraiamo le statistiche sufficienti:

$$n_M^{rj} \text{ (match), } n_S^{rj} \text{ (sostituzioni), } n_I^{rj} \text{ (inserzioni), } n_D^{rj} \text{ (delezioni),}$$

con lunghezza allineata (numero di colonne) $N^{rj} = n_M^{rj} + n_S^{rj} + n_I^{rj} + n_D^{rj}$ e distanza di edit NM = $n_S^{rj} + n_I^{rj} + n_D^{rj}$. Se la lettura presenta un allineamento *supplementare* (split), sia $\mathcal{S}_r$ l'insieme

delle coppie (a, b) di riferimenti che spiegano i due segmenti disgiunti (dal tag **SA**); per ciascun segmento disponiamo delle stesse statistiche sufficienti. La Tabella 1 riassume i simboli.

Simbolo	Significato
$\theta = (\theta_1, \dots, \theta_J)$	abbondanze relative dei riferimenti, $\sum_j \theta_j = 1$
$\mathbf{e} = (e_M, e_S, e_I, e_D)$	parametri del modello d'errore (categorica su operazioni), $\sum_O e_O = 1$
π	probabilità a priori che una lettura <i>con split</i> sia chimerica
z_r	stato latente della lettura r (sorgente singola, o coppia chimerica)
$L(r j)$	verosimiglianza dell'allineamento di r al riferimento j
γ_{rj}, ρ_r	responsabilità posteriori (sorgente j / chimera)
$\text{lin}(j)$	lineage tassonomico del riferimento j

Table 1: Notazione principale.

3 Modello generativo

Ogni lettura è generata da uno stato latente z_r . Sia $\mathbb{K}_r^{\text{sp}} = 1$ se la lettura presenta un allineamento supplementare (split), altrimenti 0. La storia generativa è:

1. **Chimera?** $c_r \sim \text{Bernoulli}(\pi \mathbb{K}_r^{\text{sp}})$. Una lettura senza split non può essere chimerica ($c_r = 0$).
2. **Se $c_r = 0$:** si estrae una sorgente $z_r = j$ da una categorica $\propto \theta_j$ ristretta a $\mathcal{C}_r$; la lettura è una copia rumorosa del riferimento j sotto il modello d'errore $\mathbf{e}$, che induce l'allineamento osservato con verosimiglianza $L(r | j)$.
3. **Se $c_r = 1$:** si estraggono due sorgenti (a, b) con probabilità $\propto \theta_a \theta_b$ ristretta a $\mathcal{S}_r$; i due segmenti sono copie rumorose di a e b , con verosimiglianza $L_{\text{chim}}(r | a, b)$ (Sez. 5).

La restrizione a $\mathcal{C}_r$ e $\mathcal{S}_r$ è l'approssimazione “candidate-set”: i riferimenti non colpiti da minimap2 hanno verosimiglianza trascurabile e si escludono, rendendo il calcolo lineare nel numero di allineamenti candidati anziché in J .

4 Modello d'errore indel-aware

Condizioniamo sull'allineamento riportato da minimap2 (logica pair-HMM [2]): la verosimiglianza è il prodotto delle probabilità delle operazioni lungo il cammino di allineamento. Con la categorica per-operazione $\mathbf{e} = (e_M, e_S, e_I, e_D)$:

$$\log L(r | j) = \underbrace{n_M^{rj} \log e_M + n_S^{rj} \log e_S + n_I^{rj} \log e_I + n_D^{rj} \log e_D}_{\text{cammino di operazioni}} + \underbrace{n_S^{rj} \log \frac{1}{3} + n_I^{rj} \log \frac{1}{4}}_{\text{scelta della base}}. \quad (1)$$

Spiegazione. Ogni colonna dell'allineamento è un'operazione (match, sostituzione, inserzione, delezione) con probabilità e_O ; il termine $\log \frac{1}{3}$ pesa la scelta della base sostituita (3 alternative), $\log \frac{1}{4}$ quella della base inserita. Match e delezioni sono deterministiche data la reference, quindi non hanno termine di scelta della base. Il carattere *indel-aware* sta nel tenere e_I ed e_D come parametri *liberi e distinti* da e_S : l'errore ONT R10 è dominato dagli indel, e un modello a sole sostituzioni (come tipico nel corto) sarebbe mis-specificato. I parametri $\mathbf{e}$ non sono fissati a priori ma *stimati* dai dati (Sez. 7), quindi il modello si adatta alla chimica di sequenziamento.

Nota su clip e copertura. Poiché LOREON impone già una copertura di query $\geq 90\%$, le code non allineate (soft-clip) sono minime e comparabili tra i candidati j della stessa lettura; la (1) è quindi valida sulla porzione allineata senza distorsioni sistematiche tra candidati. In alternativa si aggiunge un termine di penalità per base soft-clipped $n_{\text{clip}}^{rj} \log e_{\text{clip}}$.

5 Componente chimera

Per una lettura con split, i due segmenti (colonne 1 e 2) mappano a a e b su intervalli disgiunti della query. La verosimiglianza chimera fattorizza sui segmenti, ciascuno valutato con lo stesso modello d'errore (1):

$$L_{\text{chim}}(r \mid a, b) = L^{(1)}(r \mid a) \cdot L^{(2)}(r \mid b), \quad (2)$$

dove $L^{(s)}$ usa le statistiche sufficienti del solo segmento s . **Spiegazione.** Per una lettura *con* split confrontiamo due ipotesi: (a) non-chimerica, un unico riferimento j spiega l'intera lettura (eventualmente con un grande indel / variante strutturale); (b) chimera, due riferimenti spiegano i due segmenti. È una selezione di modello *per lettura*, e π diventa un parametro *stimato* (non un rapporto fisso contato dai supplementary). La versione “inter-taxon” restringe $\mathcal{S}_r$ alle coppie con $\text{lin}(a) \neq \text{lin}(b)$ a un rango scelto.

6 Verosimiglianza completa

Per unificare la notazione, a ogni lettura associamo un insieme di *ipotesi* $\mathcal{H}_r$: le ipotesi “sorgente singola j ” per $j \in \mathcal{C}_r$, più (se $\mathbb{K}_r^{\text{SP}} = 1$) le ipotesi “chimera (a, b) ” per $(a, b) \in \mathcal{S}_r$. La verosimiglianza marginale della lettura è la mistura

$$P(r \mid \boldsymbol{\theta}, \mathbf{e}, \pi) = (1 - \pi \mathbb{K}_r^{\text{SP}}) \sum_{j \in \mathcal{C}_r} \theta_j L(r \mid j) + \pi \mathbb{K}_r^{\text{SP}} \sum_{(a,b) \in \mathcal{S}_r} \theta_a \theta_b L_{\text{chim}}(r \mid a, b), \quad (3)$$

e la log-verosimiglianza osservata dell'intero campione è $\ell(\boldsymbol{\theta}, \mathbf{e}, \pi) = \sum_{r=1}^N \log P(r \mid \boldsymbol{\theta}, \mathbf{e}, \pi)$.

7 Stima per Expectation–Maximization

Introduciamo le variabili latenti complete z_r . La log-verosimiglianza *completa* è

$$\ell_c = \sum_r \left[\mathbb{K}(c_r=0) (\log(1-\pi_r) + \log \theta_{z_r} + \log L(r \mid z_r)) + \mathbb{K}(c_r=1) (\log \pi + \log \theta_{a_r} + \log \theta_{b_r} + \log L_{\text{chim}}) \right], \quad (4)$$

con $\pi_r = \pi \mathbb{K}_r^{\text{SP}}$. L'EM alterna il calcolo delle responsabilità (passo E) e l'aggiornamento dei parametri (passo M) massimizzando la funzione ausiliaria $Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{\text{old}}) = \mathbb{E}_{z \mid r, \boldsymbol{\theta}^{\text{old}}} [\ell_c]$.

7.1 Passo E: responsabilità posteriori

Dato lo stato corrente $\boldsymbol{\theta}^{\text{old}} = (\boldsymbol{\theta}, \mathbf{e}, \pi)$, per ogni lettura si normalizza sulla mistura (3):

$$\gamma_{rj} = \Pr(c_r=0, z_r=j \mid r) = \frac{(1 - \pi_r) \theta_j L(r \mid j)}{P(r)}, \quad j \in \mathcal{C}_r, \quad (5)$$

$$\rho_r(a, b) = \Pr(c_r=1, \text{sorgenti } (a, b) \mid r) = \frac{\pi \theta_a \theta_b L_{\text{chim}}(r \mid a, b)}{P(r)}, \quad \rho_r = \sum_{(a,b) \in \mathcal{S}_r} \rho_r(a, b). \quad (6)$$

Spiegazione. γ_{rj} è la probabilità posteriore che la lettura provenga (in modo non-chimerico) dal riferimento j ; ρ_r quella che sia una chimera. Per costruzione $\sum_j \gamma_{rj} + \rho_r = 1$. Le γ_{rj} sostituiscono i pesi softmax euristici: sono *vere* probabilità posteriori.

7.2 Passo M: aggiornamento dei parametri

Abbondanze $\boldsymbol{\theta}$. Massimizziamo la parte di Q che dipende da $\boldsymbol{\theta}$, $\sum_r [\sum_j \gamma_{rj} \log \theta_j + \sum_{(a,b)} \rho_r(a, b) (\log \theta_a + \log \theta_b)]$, sotto il vincolo $\sum_j \theta_j = 1$. Con il moltiplicatore di Lagrange λ :

$$\frac{\partial}{\partial \theta_j} \left[\cdot - \lambda (\sum_k \theta_k - 1) \right] = \frac{n_j}{\theta_j} - \lambda = 0 \Rightarrow \theta_j = \frac{n_j}{\lambda}, \quad \lambda = \sum_k n_k,$$

da cui l'aggiornamento in forma chiusa

$$\theta_j = \frac{n_j}{\sum_k n_k}, \quad n_j = \sum_r \gamma_{rj} + \sum_r \sum_{(a,b) \in \mathcal{S}_r} \rho_r(a,b) [\mathbb{I}(a=j) + \mathbb{I}(b=j)]. \quad (7)$$

Spiegazione. n_j è il numero *atteso* di molecole-sorgente attribuite al riferimento j : ogni lettura non-chimerica contribuisce γ_{rj} , ogni chimera contribuisce a entrambi i suoi genitori. Questo è l'EM di abbondanza (come Bracken/Emu), ma ora accoppiato all'errore e alle chimere. (Opzione: definire un'abbondanza “pulita” escludendo i contributi chimerici.)

Tasso di chimere π . Solo le letture con split ($r \in \mathcal{R}_{\text{sp}}$) informano π . Massimizzando $\sum_{r \in \mathcal{R}_{\text{sp}}} [\rho_r \log \pi + (1 - \rho_r) \log(1 - \pi)]$:

$$\pi = \frac{1}{|\mathcal{R}_{\text{sp}}|} \sum_{r \in \mathcal{R}_{\text{sp}}} \rho_r. \quad (8)$$

Modello d'errore e . È l'MLE pesato di una categorica. Sia w_{rh} la responsabilità dell'ipotesi h (una γ_{rj} o una $\rho_r(a,b)$) e n_O^{rh} il conteggio dell'operazione O sotto quell'ipotesi (per le chimere, somma sui due segmenti). Massimizzando $\sum_{r,h} w_{rh} \sum_O n_O^{rh} \log e_O$ sotto $\sum_O e_O = 1$:

$$e_O = \frac{\sum_{r,h} w_{rh} n_O^{rh}}{\sum_{r,h} w_{rh} N^{rh}} \quad (O \in \{M, S, I, D\}), \quad (9)$$

cioè la frazione attesa di colonne di tipo O sul totale. **Spiegazione.** Il modello d'errore si “allena” sui dati stessi: e_I, e_D convergono ai tassi reali di inserzione/delezione della chimica, catturando l'errore indel-dominante senza doverlo fissare a mano.

7.3 Variante MAP con prior di Dirichlet

Per stabilizzare i riferimenti rari si pone $\boldsymbol{\theta} \sim \text{Dirichlet}(\alpha)$; l'aggiornamento (7) diventa $\theta_j = (n_j + \alpha_j - 1) / \sum_k (n_k + \alpha_k - 1)$ (per $\alpha_j \geq 1$). Un α debolmente informativo evita che il rumore azzeri o gonfi taxa marginali.

7.4 Garanzia di monotonia, inizializzazione, convergenza

Per la disuguaglianza di Jensen, $\ell(\boldsymbol{\Theta}) - \ell(\boldsymbol{\Theta}^{\text{old}}) \geq Q(\boldsymbol{\Theta} \mid \boldsymbol{\Theta}^{\text{old}}) - Q(\boldsymbol{\Theta}^{\text{old}} \mid \boldsymbol{\Theta}^{\text{old}}) \geq 0$: ogni iterazione EM *non diminuisce* la log-verosimiglianza osservata. Si inizializza $\boldsymbol{\theta}^{(0)}$ dai conteggi primari normalizzati (*warm start*), $\mathbf{e}^{(0)}$ da stime di errore ONT di letteratura, $\pi^{(0)}$ dalla frazione grezza di letture con split. Criterio d'arresto: $\Delta \ell < \varepsilon_{\text{tol}}$ o numero massimo di iterazioni; per attenuare gli ottimi locali si usano restart multipli e si tiene la soluzione a ℓ massima.

8 Risoluzione tassonomica posteriore e unità adattive

Dalla parte non-chimerica normalizziamo la posteriore per-lettura $\tilde{\gamma}_{rj} = \gamma_{rj} / \sum_k \gamma_{rk}$. Per un nodo tassonomico t a un dato rango, la massa posteriore è $\Gamma_r(t) = \sum_{j: t \in \text{lin}(j)} \tilde{\gamma}_{rj}$. La *profondità di consenso* della lettura è il rango più profondo in cui un singolo nodo cattura almeno τ della massa:

$$d_r = \max \left\{ \text{rango } \ell : \max_{t \text{ al rango } \ell} \Gamma_r(t) \geq \tau \right\}. \quad (10)$$

Spiegazione. È il consenso pesato della versione euristica, ma ora Γ_r è una *probabilità posteriore* del modello congiunto, non una softmax. La qualità di un'OTU è riassunta dalla distribuzione delle d_r delle sue letture e dal support medio $\max_t \Gamma_r(t)$.

Identificabilità e unità adattive. Se due riferimenti j, j' sono quasi indistinguibili dal marcatore, $L(r | j) \approx L(r | j')$ e la verosimiglianza è piatta lungo $\theta_j + \theta_{j'} = \text{cost}$: le abbondanze *individuali* non sono identificabili, ma la loro *somma* lo è. Si riporta perciò ogni taxon all'*unità a risoluzione adattiva*: il nodo tassonomico più fine il cui intervallo di credibilità (Sez. 9) esclude lo zero. Il limite di identificabilità diventa così una proprietà dichiarata, non un errore nascosto.

9 Quantificazione dell'incertezza e calibrazione

Essendo un modello di verosimiglianza, l'incertezza si ottiene per *bootstrap non parametrico* sulle letture:

1. per $b = 1, \dots, B$: ricampiona N letture con reinserimento; rifit dell'EM (warm-started) $\Rightarrow \theta^{(b)}$;
2. intervallo di credibilità al $(1 - \alpha)$ per θ_j : percentili $[\alpha/2, 1 - \alpha/2]$ di $\{\theta_j^{(b)}\}_b$;
3. indici di diversità con incertezza: per ogni b si calcolano Shannon $H^{(b)} = -\sum_j \theta_j^{(b)} \log \theta_j^{(b)}$ e Chao1, ottenendo i rispettivi CI.

Calibrazione (il risultato-chiave). Su comunità mock a composizione nota θ^* , la *copertura empirica* al livello nominale $1 - \alpha$ è

$$\text{cov}(1 - \alpha) = \frac{1}{J} \sum_{j=1}^J \mathbb{I}(\theta_j^* \in \text{CI}_j^{1-\alpha}). \quad (11)$$

Il metodo è ben calibrato se $\text{cov}(1 - \alpha) \approx 1 - \alpha$ (curva di calibrazione vicina alla diagonale). È la proprietà statistica che nessuno strumento di metabarcoding riporta oggi e che costituisce il cuore del contributo. In alternativa al bootstrap, un prior di Dirichlet consente una posteriore variazionale/Gibbs su θ .

10 Algoritmo e complessità

Algoritmo (fit del modello).

1. Costruisci la tabella candidati per-lettura $\{\mathcal{C}_r, \mathcal{S}_r, (n_O^{rj})\}$ da una passata sul BAM.
2. Inizializza $\theta, \mathbf{e}, \pi$ (warm start).
3. **ripeti**: E-step (5)–(6); M-step (7)–(9); **finché** $\Delta \ell < \varepsilon_{\text{tol}}$.
4. **bootstrap** B volte (parallelo) $\Rightarrow$ CI su θ e diversità.
5. Aggrega le posteriori sull'albero $\Rightarrow$ risoluzione, unità adattive, output.

Il costo per iterazione EM è $O(\sum_r |\mathcal{H}_r|)$, lineare nel numero totale di allineamenti candidati (non in J). Il bootstrap moltiplica per B ma è imbarazzantemente parallelo. La memoria è dominata dalla tabella candidati (sparsa) e dall'indice minimap2; il bootstrap ricampiona indici, non copia i dati.

11 Protocollo di benchmark

Il benchmark è ciò che regge la pubblicazione: deve dimostrare accuratezza, calibrazione e generalità rispetto agli strumenti esistenti.

Dataset. Comunità *mock* a composizione nota, pubblicate, su più marcatori e regni: mock fungine ITS (composizioni even e staggered) e mock batteriche 16S (es. ZymoBIOMICS); dove possibile l'operone rRNA full-length. Verità di riferimento θ^* nota. Campioni ambientali reali per la valutazione qualitativa. Almeno due chimiche ONT (es. R9.4.1 e R10.4.1) per la robustezza.

Baseline (confronto testa-a-testa).

1. conteggio solo-primary; (2) best-hit; (3) consenso/LCA stile MEGAN [9]/Kraken2 [10];
2. ri-stima stile Bracken [7]; (5) **Emu** [8] (EM long-read, prior art diretto);
3. **TaxQuality euristico** (consenso + EM + chimera separati) come *ablazione* interna.

Metriche. *Accuratezza dell’abbondanza*: dissimilarità di Bray–Curtis e distanza di Aitchison (CLR) da θ^* , errore L_1 , correlazione di Spearman. *Ricchezza/risoluzione*: numero di OTU-specie spurie, tasso di over-split, valutati sulle unità adattive. *Calibrazione (metrica-novità)*: copertura dei CI ai livelli nominali, curva di calibrazione, ampiezza degli intervalli. *Chimere*: precisione/recall e AUROC contro chimere note (spike-in in silico e/o sperimentali).

Ablazione e generalità. Dimostrare che il modello congiunto $\geq$ somma delle tre euristiche (baseline 6) sull’accuratezza *e* che fornisce, unico, CI calibrati. Ripetere su ≥ 2 marcatori, ≥ 2 regni e ≥ 2 chimiche, riportando la consistenza dei risultati (l’elemento che parla di “metodo generale”).

Analisi statistica e criteri di successo. Test appaiati tra repliche/campioni con dimensioni d’effetto; criteri fissati *a priori*: (i) Bray–Curtis inferiore a tutte le baseline con $p < 0.05$; (ii) copertura dei CI entro ± 5 punti percentuali dal nominale; (iii) AUROC chimere > 0.9 . Tutto containerizzato, dati e seed pubblici per la riproducibilità.

12 Parametri e default proposti

Parametro	Ruolo	Default proposto
-N, -p (minimap2)	ampiezza dei candidati secondari	$N=20, p=0.5$
$\epsilon^{(0)}$	errore iniziale (M,S,I,D)	da letteratura ONT R10, poi stimato
$\pi^{(0)}$	tasso chimere iniziale	frazione grezza di letture con split
τ	soglia di consenso posteriore	0.9
α (Dirichlet)	regolarizzazione di θ	debole (es. $\alpha_j=1+\epsilon$)
B	repliche bootstrap	200–1000
ϵ_{tol}	tolleranza di convergenza	10^{-6} su ℓ

Table 2: Parametri del modello e valori di partenza consigliati.

References

- [1] Dempster AP, Laird NM, Rubin DB (1977). Maximum likelihood from incomplete data via the EM algorithm. *J. R. Stat. Soc. B* 39(1):1–38. <https://doi.org/10.1111/j.2517-6161.1977.tb01600.x>
- [2] Durbin R, Eddy SR, Krogh A, Mitchison G (1998). *Biological Sequence Analysis: Probabilistic Models of Proteins and Nucleic Acids*. Cambridge University Press.
- [3] Li H (2018). Minimap2: pairwise alignment for nucleotide sequences. *Bioinformatics* 34(18):3094–3100. <https://doi.org/10.1093/bioinformatics/bty191>
- [4] Li B, Dewey CN (2011). RSEM: accurate transcript quantification from RNA-Seq data. *BMC Bioinformatics* 12:323. <https://doi.org/10.1186/1471-2105-12-323>
- [5] Bray NL, Pimentel H, Melsted P, Pachter L (2016). Near-optimal probabilistic RNA-seq quantification. *Nat. Biotechnol.* 34:525–527. <https://doi.org/10.1038/nbt.3519>
- [6] Patro R, Duggal G, Love MI, Irizarry RA, Kingsford C (2017). Salmon provides fast and bias-aware quantification of transcript expression. *Nat. Methods* 14:417–419. <https://doi.org/10.1038/nmeth.4197>

- [7] Lu J, Breitwieser FP, Thielen P, Salzberg SL (2017). Bracken: estimating species abundance in metagenomics data. *PeerJ Comput. Sci.* 3:e104. <https://doi.org/10.7717/peerj-cs.104>
- [8] Curry KD, Wang Q, Nute MG, et al. (2022). Emu: species-level microbial community profiling of full-length 16S rRNA Oxford Nanopore sequencing data. *Nat. Methods* 19:845–853. <https://doi.org/10.1038/s41592-022-01520-4>
- [9] Huson DH, Auch AF, Qi J, Schuster SC (2007). MEGAN analysis of metagenomic data. *Genome Res.* 17:377–386. <https://doi.org/10.1101/gr.5969107>
- [10] Wood DE, Lu J, Langmead B (2019). Improved metagenomic analysis with Kraken 2. *Genome Biol.* 20:257. <https://doi.org/10.1186/s13059-019-1891-0>
- [11] Kõljalg U, Nilsson RH, Abarenkov K, et al. (2013). Towards a unified paradigm for sequence-based identification of Fungi. *Mol. Ecol.* 22(21):5271–5277. <https://doi.org/10.1111/mec.12481>
- [12] Schoch CL, Seifert KA, Huhndorf S, et al. (2012). Nuclear ribosomal ITS region as a universal DNA barcode marker for Fungi. *PNAS* 109(16):6241–6246. <https://doi.org/10.1073/pnas.1117018109>
- [13] Edgar RC, Haas BJ, Clemente JC, Quince C, Knight R (2011). UCHIME improves sensitivity and speed of chimera detection. *Bioinformatics* 27(16):2194–2200. <https://doi.org/10.1093/bioinformatics/btr381>
- [14] Callahan BJ, McMurdie PJ, Holmes SP (2017). Exact sequence variants should replace operational taxonomic units. *ISME J.* 11:2639–2643. <https://doi.org/10.1038/ismej.2017.119>

Documento di design: describe una ri-progettazione proposta, non ancora implementata. I riferimenti primari sono stati verificati sull'editore; Emu è citato come prior art diretto contro cui posizionare il contributo.