

Identificazione della sequenza di riferimento più prossima nella profilazione di comunità fungine da sequenziamento long-read

Logica, validazione sperimentale e limiti della fase di miglioramento del modulo TaxQuality
(pipeline LOREON)

Roberto Scarponi — Dipartimento di Scienze Farmaceutiche, Università degli Studi di Perugia

26 luglio 2026

Indice

1	Premessa: la domanda a cui questa fase risponde	2
2	La logica in quattro passi	2
2.1	Passo 1 — Rendere visibili le alternative	2
2.2	Passo 2 — Pesare le alternative	2
2.3	Passo 3 — Stabilire fino a che profondità tassonomica l'evidenza regge	3
2.4	Passo 4 — Ridistribuire le letture ambigue secondo verosimiglianza	4
3	Risultati sulle comunità artificiali	4
3.1	Impostazione della validazione	4
3.2	Esito	4
3.3	Taratura dei parametri e sua verifica	5
4	Il limite fondamentale: quando la sequenza più prossima non è quella giusta	6
4.1	L'osservazione	6
4.2	La spiegazione	6
5	L'esperimento di esclusione controllata	7
5.1	Impostazione	7
5.2	Primo esito: metà dei casi non è sondabile	7
5.3	Secondo esito: il predittore della rilevabilità non è la distanza genetica	7
5.4	Interpretazione biologica	7
5.5	Terzo esito: un indicatore utile, entro il proprio dominio	8
6	Limiti	9
7	Possibili miglioramenti	9
	Bibliografia	11

1 Premessa: la domanda a cui questa fase risponde

Nella profilazione di comunità microbiche mediante marcatori molecolari, ogni lettura di sequenziamento viene confrontata con un archivio di sequenze di riferimento e assegnata a quella che le somiglia di più. L'esito di questo confronto — chiamato convenzionalmente assegnazione *primaria* — costituisce il dato elementare su cui si fondano tutte le stime successive: abbondanze relative, ricchezza specifica, indici di diversità.

Questa fase di lavoro nasce da un'osservazione semplice e da una domanda che ne discende.

L'osservazione. L'assegnazione primaria non è una misura, ma una **scelta**. Quando la lettura somiglia quasi ugualmente a più sequenze di riferimento — situazione ordinaria per il marcatore ITS in archivi come UNITE, che contengono migliaia di specie strettamente imparentate — l'algoritmo di allineamento ne designa una sola, e le altre scompaiono dal risultato. La scelta è governata da differenze di punteggio spesso irrisorie, talvolta nulle.

La domanda. *Quanto è realmente prossima, alla lettura osservata, la sequenza dichiarata primaria? E quali altre sequenze sono altrettanto prossime, o più prossime di quanto il risultato lasci intendere?*

Rispondere a questa domanda significa passare da un'attribuzione categorica — questa lettura appartiene a questa specie — a una descrizione probabilistica dell'evidenza disponibile. È il contenuto della fase di miglioramento qui documentata.

Il presente documento espone la logica adottata, i risultati ottenuti su comunità artificiali a composizione nota, e — in chiusura — il limite fondamentale che l'indagine ha portato alla luce, insieme alle direzioni per superarlo. Si è scelto un registro descrittivo, privo di dettagli implementativi, che privilegia il ragionamento statistico e la sua interpretazione biologica.

2 La logica in quattro passi

2.1 Passo 1 — Rendere visibili le alternative

La prima decisione è stata di natura conoscitiva prima che metodologica: **conservare le alternative anziché scartarle**. L'allineatore, nella configurazione ordinaria, riporta per ogni lettura la sola corrispondenza migliore; le corrispondenze secondarie vengono soppresse per economia di calcolo e di spazio.

Recuperandole, il dato elementare cambia natura: da un'attribuzione singola si passa a un **insieme di ipotesi concorrenti**, ciascuna corredata dal proprio punteggio di allineamento. Sui dati in esame l'insieme conta mediamente dieci sequenze candidate per lettura (Figura 1a): dieci riferimenti che l'algoritmo giudica compatibili con la lettura osservata, e dei quali soltanto uno sopravviveva al risultato finale.

Questa scelta ha un costo — l'archivio degli allineamenti cresce di circa un quinto — ed è quindi attivabile a discrezione dell'operatore, restando la procedura ordinaria immutata quando non richiesta.

2.2 Passo 2 — Pesare le alternative

Disporre di dieci candidati non risolve nulla se non si stabilisce **quanto** ciascuno sia plausibile. Il punteggio di allineamento fornisce l'informazione necessaria: esso cresce con il numero di basi corrispondenti e decresce con le differenze osservate, e la differenza di punteggio fra due candidati è quindi proporzionale al numero di posizioni in cui essi divergono rispetto alla lettura.

Si è adottata una trasformazione che converte i punteggi in **pesi di verosimiglianza relativa**, normalizzati a somma unitaria per ciascuna lettura. La costante che regola la severità della trasformazione è stata

fissata in corrispondenza del costo di una singola differenza nucleotidica: un candidato che diverga di una posizione in più rispetto al migliore riceve un peso di circa un terzo. Si tratta di una taratura volutamente **prudente** — un’analisi formale del sistema di punteggio suggerirebbe una severità circa tripla — nel senso che il metodo dichiara più ambiguità residua di quanta i punteggi rigorosamente comportino.

L’adeguatezza di questa scelta è stata verificata *a posteriori* mediante una procedura di convalida incrociata, escludendo a turno una comunità e ottimizzando la costante sulle rimanenti (§4.1): la taratura ottimizzata non generalizza, e il valore prudente adottato risulta preferibile.

Il divario di punteggio fra la prima e la seconda scelta è, di per sé, una quantità informativa: la sua distribuzione (Figura 1b) separa nettamente le unità tassonomiche realmente presenti nelle comunità artificiali da quelle spurie (mediana 60 contro 30). Questa osservazione tornerà centrale al §5.




Figura 1: **Figura 1.** (a) Distribuzione del numero di sequenze candidate per lettura, dopo il recupero delle corrispondenze secondarie. (b) Distribuzione del divario di punteggio fra prima e seconda scelta, distinta fra unità tassonomiche attese nelle comunità artificiali e unità spurie; le linee tratteggiate indicano le mediane.

2.3 Passo 3 — Stabilire fino a che profondità tassonomica l’evidenza regge

Pesare i candidati consente di porre una domanda più fine di “quale specie?”: **a quale rango tassonomico l’evidenza è sufficiente?**

Per ciascuna lettura si risale la gerarchia tassonomica — dalla specie verso il genere, la famiglia, l’ordine — e si individua il rango più profondo in cui un singolo taxon raccoglie almeno il 90% del peso complessivo dei candidati. Una lettura i cui candidati siano due specie del medesimo genere non viene dichiarata ambigua: viene dichiarata **certa a livello di genere e indeterminata a livello di specie**, che è l’informazione corretta.

Due precisazioni metodologiche hanno rilevanza biologica diretta:

- La soglia di consenso è riferita alla sola massa **effettivamente annotata** a quel rango. Una sequenza di riferimento priva dell’epiteto specifico costituisce un’informazione mancante, non un disaccordo; addebitarla come tale trasferirebbe l’incompletezza dell’archivio sul campione analizzato, attribuendo al materiale biologico un’ambiguità che appartiene invece alla base di conoscenza.

- I ranghi tassonomici sono grandezze **ordinali** e non ammettono medie. La risoluzione tipica di un'unità viene perciò riportata come rango modale, accompagnato dalla distribuzione completa delle profondità; una media produrrebbe ranghi che nessuna lettura sostiene.

Il criterio di consenso adottato è concettualmente affine alla soglia di *bootstrap* impiegata nei classificatori tassonomici bayesiani (Wang et al. 2007), e la sua severità è stata parimenti sottoposta a verifica (§4.1).

2.4 Passo 4 — Ridistribuire le letture ambigue secondo verosimiglianza

L'ultimo passo affronta la conseguenza quantitativa del problema. Se dieci letture sono compatibili con due specie indistinguibili, attribuirle tutte a quella che ha vinto un confronto marginale introduce una distorsione sistematica, tanto più grave quanto più l'archivio contiene sequenze ridondanti.

Si è adottata la ridistribuzione per **massima verosimiglianza** mediante algoritmo di attesa-massimizzazione (Dempster et al. 1977), approccio consolidato nella quantificazione dei trascritti (Li e Dewey 2011; Bray et al. 2016) e trasferito alla metagenomica (Lu et al. 2017) e più recentemente agli ampliconi long-read (Curry et al. 2022). Il principio è che le letture attribuibili senza ambiguità a un solo riferimento — le uniche realmente informative — determinano le abbondanze relative, e queste a loro volta guidano la ripartizione delle letture ambigue.

Un aspetto ha richiesto particolare attenzione. Se la procedura viene inizializzata dai conteggi primari, un riferimento che non vinca mai un confronto parte da abbondanza nulla e **non può più riceverne**: la sua esclusione si autoconferma a ogni iterazione. Poiché è esattamente la condizione delle sequenze indistinguibili — quelle per cui la ridistribuzione esiste — si è adottata un'inizializzazione uniforme, conformemente alla pratica consolidata nel settore (Li e Dewey 2011; Bray et al. 2016). Su due accessioni UNITE identiche nel tratto amplificato, i conteggi primari 33 e 27 diventano 30,0 e 30,0: la ripartizione arbitraria operata dall'allineatore viene rimossa anziché ereditata.

3 Risultati sulle comunità artificiali

3.1 Impostazione della validazione

Sono state impiegate sei comunità artificiali di lieviti a composizione nota (quattro-sei specie ciascuna, proporzioni definite), amplificate per la regione ITS e sequenziate su piattaforma Oxford Nanopore (Conti et al. 2023); l'insieme comprende 18 campioni e circa 250.000 letture. Ogni stima è stata confrontata con la composizione attesa, calcolando precisione (quota di taxa rilevati effettivamente presenti), richiamo (quota di taxa attesi effettivamente rilevati) e la loro media armonica F1, alla soglia di abbondanza relativa dello 0,05%.

3.2 Esito

Stima	Precisione	Richiamo	F1	Falsi positivi per comunità
Conteggio primario	0,179	0,539	0,262	12,8
Ridistribuzione per verosimiglianza	0,227	0,539	0,316	9,0

Il miglioramento dell'indice F1 è del **21%**, interamente attribuibile alla precisione: il richiamo resta invariato, mentre i taxa spuri diminuiscono di quasi un terzo (Figura 2). Il guadagno è coerente in tutte e sei le comunità e non deriva da alcuna ottimizzazione dei parametri (§4.1).




Figura 2: **Figura 2.** (a) Precisione, richiamo e indice F1 medi sulle sei comunità artificiali, alla soglia di abbondanza relativa dello 0,05%. (b) Numero medio di taxa spuri rilevati per comunità.

Va segnalato con altrettanta chiarezza ciò che **non** migliora. Le misure di accordo fra abbondanze osservate e attese — correlazione di Pearson e dissimilarità di Bray-Curtis — restano invariate (0,396 e 0,686 rispettivamente). La procedura corregge dunque *quali* taxa vengono dichiarati presenti, non *in quale proporzione*. È una precisazione necessaria: il beneficio riguarda la composizione qualitativa della comunità, non la sua struttura quantitativa.

3.3 Taratura dei parametri e sua verifica

Tre grandezze governano il procedimento: la severità della pesatura dei candidati, la soglia di consenso tassonomico e un'eventuale regolarizzazione delle abbondanze rare. Tutte e tre sono state sottoposte a esplorazione sistematica (28 combinazioni) con convalida incrociata per esclusione di una comunità alla volta.

L'esito è stato conservativo e, a suo modo, rassicurante:

- la taratura ottimizzata **non generalizza**: selezionare i parametri su cinque comunità e applicarli alla sesta produce risultati inferiori a quelli dei valori prudenti adottati (F1 0,312 contro 0,316), e i vincitori variano da una esclusione all'altra;
- la regolarizzazione delle abbondanze rare peggiora l'accuratezza a ogni livello di severità;
- la soglia di consenso è priva di effetto discriminante in tutto l'intervallo esplorato;
- l'informazione contenuta nei punteggi vale complessivamente un incremento sostanziale: azzerandola — cioè trattando tutti i candidati come equivalenti — la prestazione scende al di sotto del semplice conteggio primario.

I valori originari sono stati quindi mantenuti, ma la loro adozione poggia ora su una verifica statistica anziché su una scelta di convenienza.

4 Il limite fondamentale: quando la sequenza più prossima non è quella giusta

4.1 L'osservazione

Una delle sei comunità — composta da quattro specie congeneriche dei generi *Debaryomyces* e *Dipodascus* — ha prodotto un esito qualitativamente inverso: l'87% delle letture attribuito a due specie **assenti** dalla comunità, e le quattro specie attese complessivamente al 3%.

L'aspetto istruttivo non è l'errore, ma il corredo di garanzie che lo accompagna. Le due assegnazioni errate risultano risolte a livello di specie per il 93% e il 99,7% delle letture, con sostegno di consenso pari a 1,00 — il massimo possibile. Applicando la ridistribuzione per verosimiglianza, l'errore non si corregge: si accentua, dall'87% al 93%. E gli intervalli di credibilità ottenuti per riampionamento delle letture dichiarano con confidenza del 95% che la specie dominante attesa — il 40% reale della comunità — è presente allo 0,00%, con estremi [0,00%; 0,00%]. La copertura empirica di tali intervalli, misurata su tutte le comunità, è del 4% a fronte di un valore nominale del 95%.

4.2 La spiegazione

Tutti gli strumenti di controllo descritti ai passi 2–4 condividono una proprietà: sono misure **relative**, calcolate all'interno dell'insieme dei candidati.

Strumento	Grandezza misurata	Ragione dell'insuccesso
Consenso tassonomico	disaccordo <i>fra</i> i candidati	se tutti i candidati sono errati ma uno prevale nettamente, non vi è disaccordo da rilevare
Ridistribuzione per verosimiglianza	ripartizione <i>relativa</i> della massa	normalizza su un insieme che non contiene la risposta corretta: le probabilità sommano comunque a uno
Riampionamento delle letture	variabilità di campionamento	con centinaia di migliaia di letture è trascurabile; l'errore qui è di natura epistemica

Manca una misura **assoluta**: quanto bene la migliore ipotesi disponibile spieghi effettivamente i dati. La domanda “e se nessuno di questi riferimenti fosse quello giusto?” non viene posta da alcuno dei tre.

Il fenomeno ha radici biologiche note. Il marcatore ITS presenta una variabilità intraspecifica non trascurabile e, in alcuni cladi, una separazione interspecifica insufficiente (Nilsson et al. 2008; Estensmo et al. 2021); la copertura degli archivi di riferimento resta parziale, al punto che la stessa comunità UNITE ha coniato la nozione di *dark taxa* per le entità non riconducibili a una specie descritta (Nilsson et al. 2019; Abarenkov et al. 2023). L'accuratezza dell'identificazione fungina su base molecolare è, per queste ragioni, strutturalmente limitata (Lücking et al. 2020).

5 L'esperimento di esclusione controllata

5.1 Impostazione

Poiché la condizione critica — assenza del riferimento corretto — può essere **prodotta deliberatamente**, si è progettato un esperimento che la realizza su verità nota. Per ciascuna comunità e ciascuna specie attesa, si rimuovono dall'archivio tutte le sequenze di quella specie e si ripete l'analisi, osservando dove migrano le letture rimaste orfane e se qualche indicatore ne registra la partenza. Sono state esaminate 30 combinazioni; un caso è stato ripetuto con riallineamento integrale contro l'archivio ridotto, come controllo di validità della procedura rapida.

5.2 Primo esito: metà dei casi non è sondabile

In 15 combinazioni su 30 la specie da rimuovere **non riceve già alcuna lettura** nell'analisi ordinaria: le sue letture giacciono su parenti indistinguibili. Il fenomeno riguarda per intero la comunità congenerica sopra descritta e diverse specie del genere *Saccharomyces*. L'esperimento può misurare la perdita di ciò che si possiede, non di ciò che non si è mai posseduto — e questa asimmetria è essa stessa un risultato: **metà delle specie attese si trova già oggi in condizione di irrisolvibilità silenziosa**.

5.3 Secondo esito: il predittore della rilevabilità non è la distanza genetica

Nei 15 casi sondabili si è misurata, per ciascuno, la divergenza aggiuntiva indotta dalla rimozione (l'aumento della distanza fra lettura e miglior riferimento residuo) e la variazione del divario di punteggio fra prima e seconda scelta — quest'ultima interpretabile come segnale di allarme.

Contrariamente all'attesa, la divergenza genetica **non** predice la rilevabilità (ρ di Spearman = +0,34; $p = 0,22$). Il predittore significativo è la **concentrazione della destinazione**, ossia quanta parte delle letture orfane confluisca su un unico taxon ricevente ($\rho = -0,60$; $p = 0,019$). La separazione è netta:

Struttura del vicinato ricevente	Casi	Rilevati	Variazione mediana del divario
Destinazione dispersa (< 70% su un unico taxon)	7	6	+47% (il divario si riduce: allarme)
Destinazione unica ($\geq 70\%$ su un unico taxon)	8	0	-185% (il divario aumenta)

Il secondo risultato merita di essere esplicitato: quando la specie mancante possiede un unico congenero ben rappresentato, le letture vi confluiscono compatte e l'assegnazione errata appare **più sicura di prima**. L'errore non solo sfugge al rilevamento: si maschera attivamente.

In tutti e quindici i casi, inoltre, il consenso tassonomico non registra alcuna variazione (sostegno fra 0,98 e 1,00 dopo la rimozione del riferimento corretto).

5.4 Interpretazione biologica

Il quadro che emerge è coerente e ha una lettura naturale in termini di struttura filogenetica dell'archivio di riferimento. Ciò che rende un'assenza percepibile non è la lontananza evolutiva della specie mancante, ma la **configurazione del suo intorno**:




Figura 3: **Figura 3.** Esito dell'esperimento di esclusione controllata (15 configurazioni sondabili). (a) La divergenza genetica aggiuntiva non predice la rilevabilità. (b) La concentrazione della destinazione la predice: con vicinato degenerare l'assenza è percepibile, con congenere unico non lo è mai. (c) Il consenso tassonomico resta invariato in ogni configurazione. I colori distinguono i generi.

- se l'intorno è **degenere** — una nube di parenti pressoché equidistanti — le letture orfane si disperdono, nessun riferimento le rivendica con autorità, e il divario di punteggio collassa: l'assenza lascia una traccia misurabile;
- se l'intorno contiene un **unico sostituto pulito**, le letture vi migrano in blocco e ogni indicatore statistico migliora: l'assenza non lascia traccia alcuna.

Ne discende un corollario di rilievo pratico. Nei casi congenerici l'85–99% della massa migra comunque **all'interno del genere corretto**: la ricostruzione resta fedele a livello di genere e inaffidabile a livello di specie. Riportare l'esito al rango effettivamente sostenuto dai dati sanerebbe la maggioranza di questi casi, senza richiedere alcuna capacità di rilevamento aggiuntiva.

5.5 Terzo esito: un indicatore utile, entro il proprio dominio

Il divario di punteggio fra prima e seconda scelta è riflesso da una grandezza che l'allineatore già fornisce, la qualità di mappatura (Li 2018) — le due quantità risultano fortemente associate ($\rho = 0,77$; $p < 0,001$). Impiegata come discriminante fra unità tassonomiche autentiche e spurie e ponderata per abbondanza, tale grandezza raggiunge un'area sotto la curva ROC di 0,97, contro 0,62–0,78 delle misure di consenso.

Alla luce dell'esperimento di esclusione, questo risultato va però **circoscritto**: l'indicatore intercetta i casi a vicinato degenerare — che comprendono i due falsi positivi dominanti della comunità congenerica — ma non la sostituzione con un congenere unico. È stato pertanto integrato nel rapporto analitico come **strumento di segnalazione**, corredato dall'indicazione esplicita del proprio dominio di validità, e non come filtro automatico.

6 Limiti

Limite primario — la sostituzione congenerica non è rilevabile. Quando l'archivio contiene un solo parente stretto ben rappresentato, nessuna delle grandezze oggi calcolate segnala l'assenza della specie corretta; anzi, gli indicatori migliorano. Il dominio di cecità comprende, nel materiale esaminato, tutti i casi a destinazione concentrata, indipendentemente dalla distanza genetica.

Confidenza e correttezza sono grandezze distinte. Le misure di risoluzione e sostegno quantificano la *concordanza fra i riferimenti disponibili*, non la loro correttezza. Un valore massimo di sostegno è compatibile con un'attribuzione integralmente errata; questa proprietà è strutturale e va dichiarata in ogni impiego dei risultati.

Le stime di incertezza correnti non sono calibrate. Gli intervalli ottenuti per riampionamento delle letture presentano copertura empirica del 4% contro un valore nominale del 95%, poiché misurano la sola variabilità di campionamento e non l'incertezza derivante dall'incompletezza dell'archivio. Non se ne raccomanda l'uso in questa forma.

La correzione riguarda la presenza, non la proporzione. Il guadagno documentato al §3 concerne precisione e ricchezza; l'accordo fra abbondanze osservate e attese resta invariato.

Ridondanza dell'archivio. Le sequenze di riferimento sono raggruppate in ipotesi di specie (Köljalg et al. 2013), ma una medesima specie può comparire sotto molte ipotesi distinte: nel materiale in esame *Saccharomyces cerevisiae* è ripartita su 31 unità. La ridistribuzione opera sul singolo riferimento e non le fonde; per l'analisi della ricchezza è necessaria un'aggregazione per etichetta tassonomica.

Estensione della validazione. I risultati provengono da sei comunità artificiali, un solo marcatore, un solo archivio di riferimento e una sola chimica di sequenziamento. Le grandezze riportate — in particolare l'area sotto la curva ROC dell'indicatore di segnalazione — sono misurate sullo stesso materiale su cui l'indicatore è stato individuato, e attendono conferma indipendente.

Un modello statistico più ricco non ha migliorato l'esito. È stato realizzato e valutato un modello probabilistico completo, comprensivo di un modello d'errore stimato dai dati e del trattamento esplicito delle letture chimeriche. Su questo materiale esso risulta **meno accurato** della procedura più semplice (F1 0,134 contro 0,316), poiché la verosimiglianza calcolata posizione per posizione discrimina meno efficacemente del punteggio di allineamento complessivo, che incorpora l'intera ottimizzazione dell'allineatore. Il risultato è stato verificato escludendo tre spiegazioni alternative.

7 Possibili miglioramenti

Le direzioni seguenti sono ordinate per rapporto fra valore atteso e onere di realizzazione. Le prime due sono prive di rischio metodologico; la terza costituisce il nucleo innovativo.

(i) Verifica di plausibilità assoluta per ciascuna lettura. Anziché confrontare i candidati fra loro, chiedersi se l'allineamento osservato con il migliore di essi sia compatibile con il tasso di errore del sequenziatore, stimato dai dati stessi. Una divergenza eccedente quella spiegabile dall'errore strumentale segnala che il riferimento corretto potrebbe non essere presente. La grandezza aggregata per unità tassonomica — *quota di letture mal spiegate* — sarebbe la prima misura assoluta del sistema. L'esperimento di esclusione ne definisce già il dominio atteso: potenza nei vicinati degeneri, potenza ridotta nella sostituzione congenerica.

(ii) Riportare l'esito al rango effettivamente sostenuto. Quando due riferimenti sono indistinguibili, le abbondanze individuali non sono identificabili ma la loro somma lo è. Riportare il taxon al rango

tassonomico più fine sostenuto dai dati trasformerebbe un errore silenzioso in una proprietà dichiarata e sanerebbe, come mostrato al §5.3, la maggioranza dei casi congenerici.

(iii) Stima della frazione di comunità non rappresentata. Estendere il modello con una componente esplicita di *sorgente ignota*, la cui verosimiglianza sia costruita marginalizzando sulla distribuzione delle divergenze fra congeneri — distribuzione stimabile dall'archivio stesso, e già oggetto dello strumento gemello di analisi dei database di riferimento sviluppato nel medesimo progetto di dottorato. Il parametro risultante fornirebbe, per ciascun campione, la stima della quota di comunità che l'archivio non è in grado di spiegare: una grandezza che nessuno strumento attualmente riporta e che l'analisi ecologica richiede. Il rischio principale è di natura statistica — la possibile non distinguibilità fra tale parametro e il tasso d'errore, entrambi compatibili con divergenze elevate — e va verificato formalmente prima di procedere.

(iv) Incertezza riferita all'archivio anziché alle letture. Sostituire il riampionamento delle letture con perturbazioni ripetute dell'archivio di riferimento: la stabilità delle abbondanze al variare dell'insieme dei riferimenti è la forma di incertezza pertinente al problema, e produrrebbe intervalli che si allargano dove l'attribuzione è fragile.

(v) Estensione della validazione. Completare l'esperimento di esclusione con riallineamento integrale su una griglia di distanze, e replicare l'intero impianto su un secondo marcatore, un secondo regno e una seconda chimica di sequenziamento.

Un'ultima considerazione, che riteniamo la più rilevante sul piano interpretativo. L'esperimento di esclusione conferma per via indipendente che **nessuna correzione statistica applicata a valle recupera informazione che il marcatore non contiene**: nella comunità congenerica la ridistribuzione peggiora l'esito, mentre l'impiego di un marcatore più esteso lo risolve. Il miglioramento documentato in questa fase agisce sull'inferenza; il limite residuo appartiene al disegno molecolare e alla completezza dell'archivio, e in quella sede va affrontato.

Bibliografia

- Abarenkov, Kessy, R. Henrik Nilsson, Karl-Henrik Larsson, et al. 2023. «The UNITE Database for Molecular Identification and Taxonomic Communication of Fungi and Other Eukaryotes: Sequences, Taxa and Classifications Reconsidered». *Nucleic Acids Research* 52 (D1): D791–97. <https://doi.org/10.1093/nar/gkad1039>.
- Bray, Nicolas L., Harold Pimentel, Páll Melsted, e Lior Pachter. 2016. «Near-Optimal Probabilistic RNA-Seq Quantification». *Nature Biotechnology* 34 (5): 525–27. <https://doi.org/10.1038/nbt.3519>.
- Conti, Angela, Debora Casagrande Pierantoni, Vincent Robert, Laura Corte, e Gianluigi Cardinali. 2023. «MinION Sequencing of Yeast Mock Communities to Assess the Effect of Databases and ITS-LSU Markers on the Reliability of Metabarcoding Analysis». *Microbiology Spectrum* 11 (1): e01052–22. <https://doi.org/10.1128/spectrum.01052-22>.
- Curry, Kristen D., Qi Wang, Michael G. Nute, et al. 2022. «Emu: Species-Level Microbial Community Profiling of Full-Length 16S rRNA Oxford Nanopore Sequencing Data». *Nature Methods* 19 (7): 845–53. <https://doi.org/10.1038/s41592-022-01520-4>.
- Dempster, A. P., N. M. Laird, e D. B. Rubin. 1977. «Maximum Likelihood from Incomplete Data via the EM Algorithm». *Journal of the Royal Statistical Society: Series B* 39 (1): 1–38. <https://doi.org/10.1111/j.2517-6161.1977.tb01600.x>.
- Estensmo, Eva Lena F., Sundry Maurice, Luis Morgado, Pedro M. Martin-Sanchez, Inger Skrede, e Håvard Kauserud. 2021. «The Influence of Intraspecific Sequence Variation during DNA Metabarcoding: A Case Study of Eleven Fungal Species». *Molecular Ecology Resources* 21 (4): 1141–48. <https://doi.org/10.1111/1755-0998.13329>.
- Kõljalg, Urmas, R. Henrik Nilsson, Kessy Abarenkov, et al. 2013. «Towards a Unified Paradigm for Sequence-Based Identification of Fungi». *Molecular Ecology* 22 (21): 5271–77. <https://doi.org/10.1111/mec.12481>.
- Li, Bo, e Colin N. Dewey. 2011. «RSEM: Accurate Transcript Quantification from RNA-Seq Data with or without a Reference Genome». *BMC Bioinformatics* 12: 323. <https://doi.org/10.1186/1471-2105-12-323>.
- Li, Heng. 2018. «Minimap2: Pairwise Alignment for Nucleotide Sequences». *Bioinformatics* 34 (18): 3094–100. <https://doi.org/10.1093/bioinformatics/bty191>.
- Lu, Jennifer, Florian P. Breitwieser, Peter Thielen, e Steven L. Salzberg. 2017. «Bracken: Estimating Species Abundance in Metagenomics Data». *PeerJ Computer Science* 3: e104. <https://doi.org/10.7717/peerj-cs.104>.
- Lücking, Robert, M. Catherine Aime, Barbara Robbertse, et al. 2020. «Unambiguous Identification of Fungi: Where Do We Stand and How Accurate and Precise Is Fungal DNA Barcoding?». *IMA Fungus* 11: 14. <https://doi.org/10.1186/s43008-020-00033-z>.
- Nilsson, R. Henrik, Erik Kristiansson, Martin Ryberg, Nils Hallenberg, e Karl-Henrik Larsson. 2008.

- «Intraspecific ITS Variability in the Kingdom Fungi as Expressed in the International Sequence Databases and Its Implications for Molecular Species Identification». *Evolutionary Bioinformatics* 4: 193–201. <https://doi.org/10.4137/EBO.S653>.
- Nilsson, R. Henrik, Karl-Henrik Larsson, Andy F. S. Taylor, et al. 2019. «The UNITE Database for Molecular Identification of Fungi: Handling Dark Taxa and Parallel Taxonomic Classifications». *Nucleic Acids Research* 47 (D1): D259–64. <https://doi.org/10.1093/nar/gky1022>.
- Wang, Qiong, George M. Garrity, James M. Tiedje, e James R. Cole. 2007. «Naïve Bayesian Classifier for Rapid Assignment of rRNA Sequences into the New Bacterial Taxonomy». *Applied and Environmental Microbiology* 73 (16): 5261–67. <https://doi.org/10.1128/AEM.00062-07>.